

EA Stephen

Data scientist

Segmentez des clients d'un site e-commerce



SOMMAIRE

- Présentation de la problématique, du cleaning effectué, du feature engineering et de l'exploration
- Présentation des différentes pistes de modélisation effectuées et du modèle final sélectionné
- Présentation de la simulation pour définir le délai de maintenance du modèle (contrat de maintenance)



Olist (solution de vente sur les marketplaces en ligne souhaite fournir à ses équipes d'e-commerce)





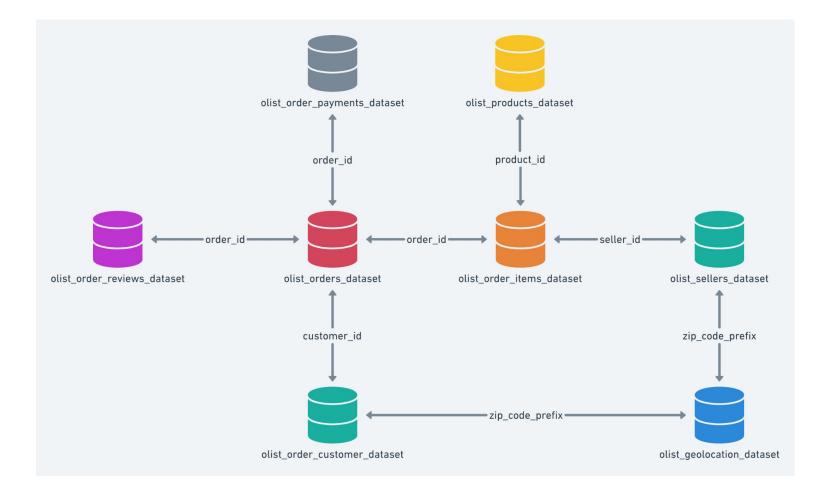
Une segmentation des clients pour leurs campagnes de communication.
La segmentation proposée doit être exploitable et facile d'utilisation pour l'équipe marketing



Une recommandation de fréquence à laquelle la segmentation doit être mise à jour pour rester pertinente, afin de pouvoir effectuer un devis de contrat de maintenance.

4 olist

Le schéma de donnée



Les produits

Le dataset : DF PRODUCT CATEGORY Les dimensions du df_product_category : (71, 2) Les valeurs manquantes dans chaque colonne :

| | Count_NaN | %_NaN_col | Types | Total_NaN_in_dataset | %_NaN_in_dataset |
|-------------------------------|-----------|-----------|--------|----------------------|------------------|
| product category name | 0 | 0.0 | object | 0 | 0.0 |
| product_category_name_english | 0 | 0.0 | object | 0 | 0.0 |

product_category_name product_category_name_english beleza_saude health_beauty Jointure left product id product category name product name length product description length product photos gty product weight g product length cm product height cm product width cm 0 1e9e8ef04dbcff4541ed26657ea517e5 perfumaria

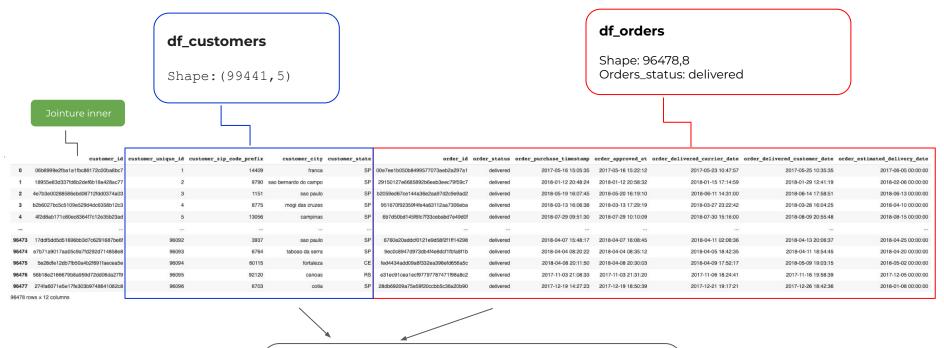
df_product_final

32951 rows × 10 columns

Le dataset : DF PRODUCTS Les dimensions du df products : (32951, 9) Les valeurs manquantes dans chaque colonne :

| | Count_NaN | %_NaN_col | Types | Total_NaN_in_dataset | %_NaN_in_dataset |
|----------------------------|-----------|-----------|---------|----------------------|------------------|
| product category name | 610 | 1.85 | object | 2448 | 0.83 |
| product name lenght | 610 | 1.85 | float64 | 2448 | 0.83 |
| product description lenght | 610 | 1.85 | float64 | 2448 | 0.83 |
| product photos gty | 610 | 1.85 | float64 | 2448 | 0.83 |
| product weight g | 2 | 0.01 | float64 | 2448 | 0.83 |
| product length cm | 2 | 0.01 | float64 | 2448 | 0.83 |
| product height cm | 2 | 0.01 | float64 | 2448 | 0.83 |
| product width cm | 2 | 0.01 | float64 | 2448 | 0.83 |
| product id | i o | 0.0 | object | 2448 | 0.83 |

Fusion entre customers et orders

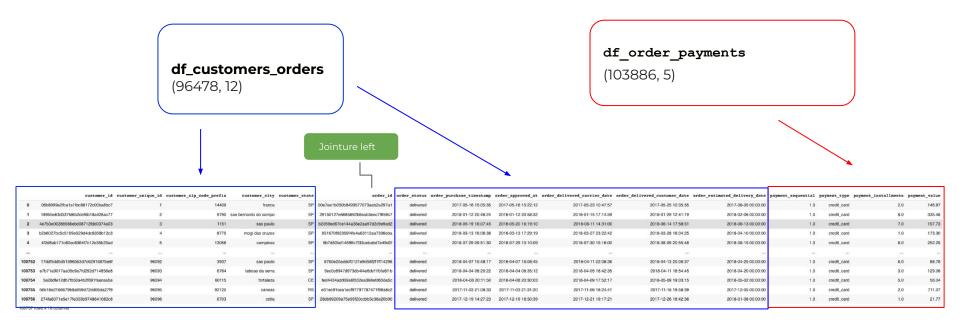


df customers orders

Le nombres de clients uniques: 93358 Le nombres de références clients: 96478 Le status des commandes: ['delivered']

7 olist

Fusion entre les commandes clients et le moyen de paiement



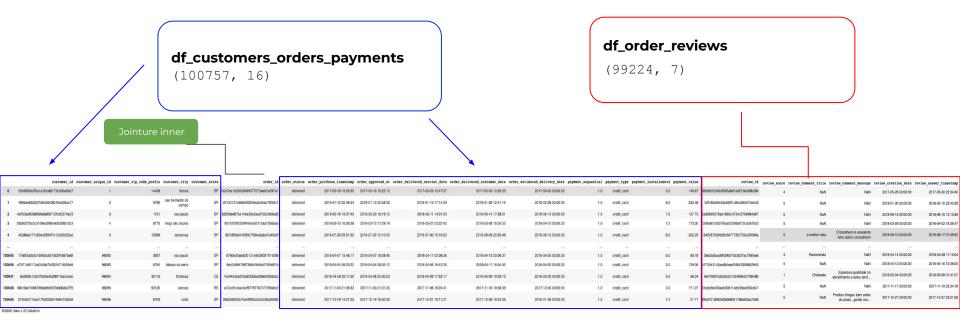
df_customers_orders_payments

100757 rows × 16 columns

Le nombres de clients uniques: 93358 Le nombres de références clients: 96478

olist

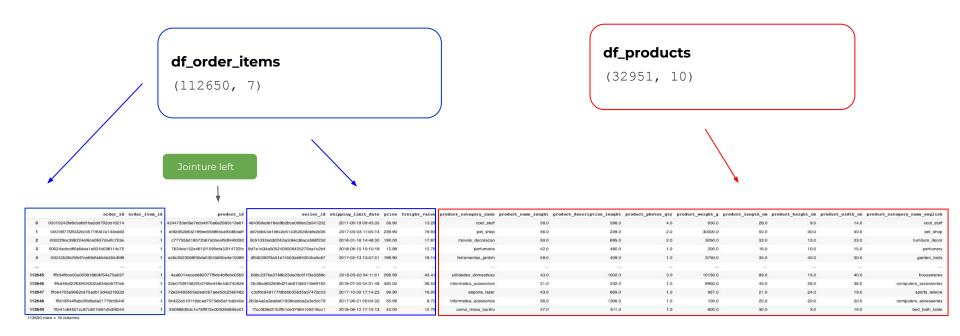
Fusion entre les commandes et la satisfaction client



df_customers_orders_payments_reviews 100650 rows × 22 columns

Le nombres de clients uniques: 92755 Le nombres de références clients: 95832

Fusion entre les produits vendus par Olist et les catégories des produits



df_order_items_products
112650 rows x 16 columns

Fusion entre le client et les articles achetés

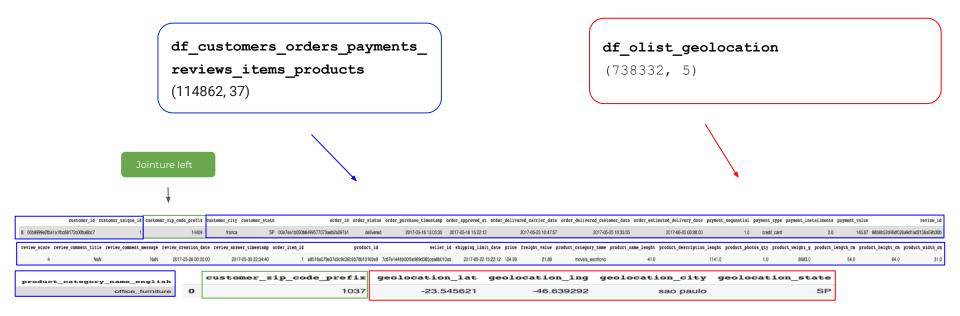


df_customers_orders_payments_reviews_items_products

114862 rows × 37 columns

Le nombres de clients uniques: 92755 Le nombres de références clients: 95832

Fusion avec la géolocation



df_final_fusion

114862 rows × 41 columns

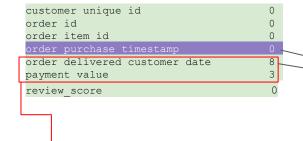
Le nombres de clients uniques: 92755 Le nombres de références clients: 95832

Data cleaning et features sélections

Les variables supprimés

| customer id | 0 |
|-------------------------------|--------|
| customer zip code prefix | 0 |
| customer city | 0 |
| customer state | 0 |
| order status | 0 |
| order approved at | 15 |
| order delivered carrier date | 2 |
| order estimated delivery date | 0 |
| payment sequential | 0 |
| payment type | 0 |
| payment installments | 0 |
| review id | 0 |
| review comment title | 101275 |
| review comment message | 0 |
| review creation date | 0 |
| review answer timestamp | 0 |
| product id | 0 |
| seller id | 0 |
| shipping limit date | 0 |
| price | 0 |
| freight value | 0 |
| product category name | 0 |
| product name lenght | 1626 |
| product description lenght | 1626 |
| product photos qty | 1626 |
| product weight g | 20 |
| product length cm | 20 |
| product height cm | 20 |
| product width cm | 20 |
| product category name english | 0 |
| geolocation lat | 302 |
| geolocation lng | 302 |
| geolocation city | 302 |
| geolocation_state | 302 |
| | |

Features sélections



Feature engineering



Supprimer les valeurs manquantes

Groupby

customer unique id

Aggrégation

order id count
order item id mean
payment value sum
review_score mean
recence mean
Duration_delevery_order mean

Drop outlier

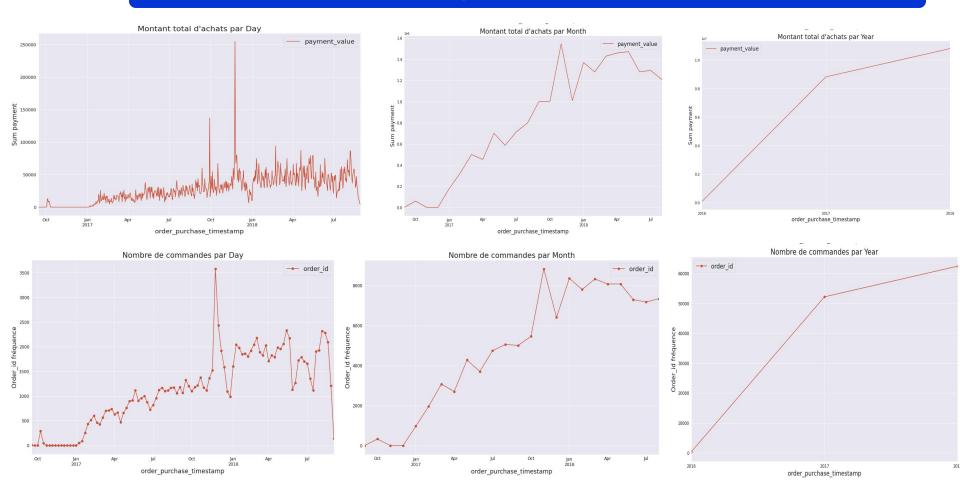
Client 6186 sensibilise le clustering et la stabilité

| | customer_unique_id | recence | frequence | mean_order_item_id | Monnaie | review_score_mean | Duration_delevery_order_mean |
|-------|--------------------|---------|-----------|--------------------|---------|-------------------|------------------------------|
| 0 | 1 | 470.0 | 1.0 | 1.0 | 146.87 | 4.0 | 9.0 |
| 1 | 2 | 229.0 | 1.0 | 1.0 | 335.48 | 5.0 | 17.0 |
| 2 | 3 | 102.0 | 1.0 | 1.0 | 157.73 | 5.0 | 26.0 |
| 3 | 4 | 169.0 | 1.0 | 1.0 | 173.30 | 5.0 | 15.0 |
| 4 | 5 | 31.0 | 1.0 | 1.0 | 252.25 | 5.0 | 11.0 |
| | *** | *** | | | | | |
| 92740 | 96092 | 144.0 | 1.0 | 1.0 | 88.78 | 4.0 | 6.0 |
| 92741 | 96093 | 147.0 | 1.0 | 1.0 | 129.06 | 5.0 | 7.0 |
| 92742 | 96094 | 143.0 | 1.0 | 1.0 | 56.04 | 1.0 | 31.0 |
| 92743 | 96095 | 299.0 | 1.0 | 1.0 | 711.07 | 5.0 | 13.0 |
| 92744 | 96096 | 253.0 | 1.0 | 1.0 | 21.77 | 5.0 | 7.0 |

92745 rows x 7 columns

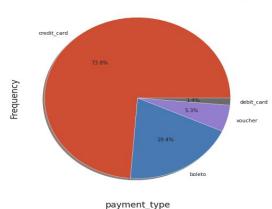
14 olist

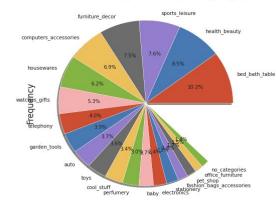
Analyse temporelle



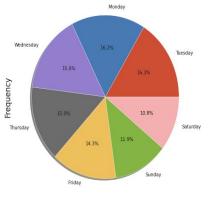
Analyse catégorielle

Répartition de la variable payment_type Répartition de la variable product_category_name_english Répartition de la variable weekday_order_purchase



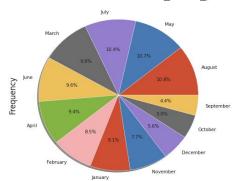


product_category_name_english



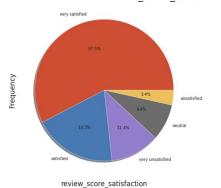
weekday_order_purchase

Répartition de la variable month_order_purchase

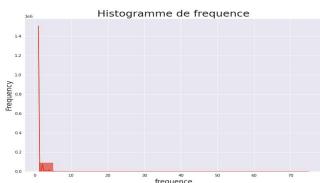


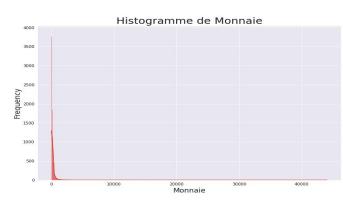
month order purchase

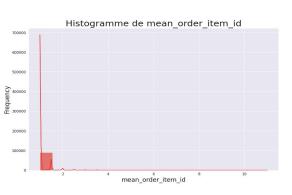
Répartition de la variable review score satisfaction



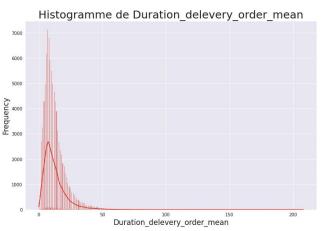












Approche clustering (kmeans)



Evaluation best K

n clusters = 4

- méthode du coude, davies_bouldin_score(0.76)
- silhouette score(0.46) ,calinski_harabasz(41342)

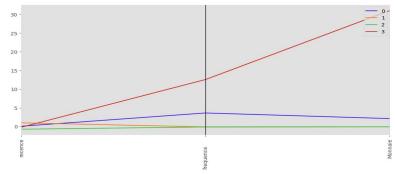
Stabilité à l'initialisation

- Stabilité moyenne pour 10 itérations

Effectifs des clusters

- pas homogène
- pas pertinent pour le besoin métier
- La fréquence à trop de poids dans la segmentation (97% clients ont passé 1 commande)

Parallel Coordinates plot for the Centroids

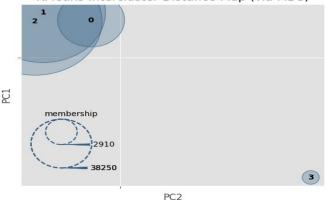


cluster 0 : 2910 cluster 1 : 38250 cluster 2 : 51547 cluster 3 : 38

Distance

- Les clusters (1 et 2) trop similaire en terme F,M
- -Cluster 3 suffisamment distant mais trop peu de clients

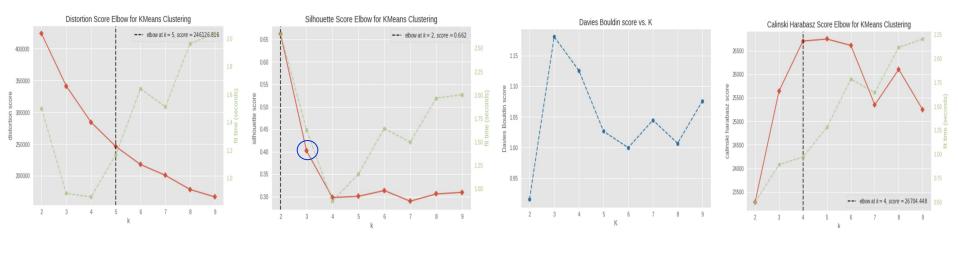
KMeans Intercluster Distance Map (via MDS)



Conclusion

La segmentation RFM pas pertinente d'un point de vue métier.

KMeans évaluation du best K (RFM, mean satisfaction, mean items, mean durée livraison)



Méthode du coude (distortion)

La moyenne de la somme des carrés des distances au centroïde le proche (coude) Silhouette score

Le coefficient de silhouette ou score de silhouette est une mesure utilisée pour calculer la qualité d'une technique de regroupement.
Sa valeur est comprise entre -1 et 1.
1: Signifie que les grappes sont bien séparées les unes des autres et clairement distinguées.
a= distance intra-cluster moyenne,
c'est-à-dire la distance moyenne entre chaque point d'un cluster.

Davies Bouldin

Le score est défini comme la mesure de similarité moyenne de chaque cluster avec son cluster le plus similaire, où la similarité est le rapport des distances intra-cluster aux distances inter-cluster. Ainsi, les clusters plus éloignés et moins dispersés donneront un meilleur score. Le score minimum est de zéro, les valeurs inférieures indiquant un meilleur regroupement.

Calinski

Le score est défini comme le rapport entre la dispersion intra-cluster et la dispersion inter-cluster.

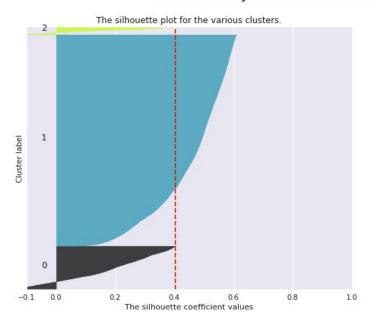
Stabilité à l'initialisation avec Kmeans

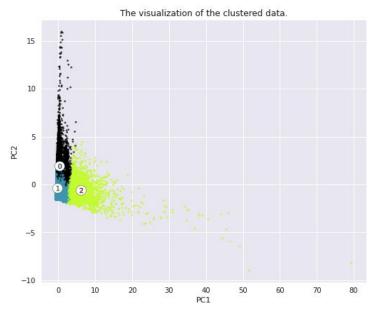
```
Iter 1(n cluster 3):
Fit time: 2.384185791015625e-07
Le score ARI 0.9999521516389113
Le score HOMO 0.9997709474649992
Le score AMI 0.9997857656100236
Iter 2(n cluster 3):
Fit time: 7.152557373046875e-07
Le score ARI 0.9959405702565177
Le score HOMO 0.9901246797240195
Le score AMI 0.9888804399395965
Iter 3(n cluster 3):
Fit time: 9.5367431640625e-07
Le score ARI 0.9999521516389113
Le score HOMO 0.9997709474649992
Le score AMI 0.9997857656100236
Iter 4(n cluster 3):
Fit time: 4.76837158203125e-07
Le score ARI 0.999904303273828
Le score HOMO 0.9995678771782378
Le score AMI 0.9995975095952087
Iter 5(n cluster 3):
_____
Fit time: 2.384185791015625e-07
Le score ARI 0.9964650441254504
Le score HOMO 0.991210947206712
Le score AMI 0.9901260596176928
```

```
Iter 6(n cluster 3):
Fit time: 7.152557373046875e-07
Le score ARI 0.9999521516389113
Le score HOMO 0.9997709474649992
Le score AMI 0.9997857656100236
Iter 7(n cluster 3):
-----
Fit time: 1.1920928955078125e-06
Le score ARI 0.9998086065314611
Le score HOMO 0.9991877183510793
Le score AMI 0.9992469672824071
Iter 8(n cluster 3):
Fit time: 2.384185791015625e-07
Le score ARI 1.0
Le score HOMO 1.0
Le score AMI 1.0
-----
Iter 9(n cluster 3):
Fit time: 9.5367431640625e-07
Le score ARI 0.999904303273828
Le score HOMO 0.9995678771782378
Le score AMI 0.9995975095952087
Iter 10(n cluster 3):
Fit time: 2.384185791015625e-07
Le score ARI 0.999904303273828
Le score HOMO 0.9995678771782378
Le score AMI 0.9995975095952087
```

Forme des clusters

Silhouette analysis for KMeans clustering on sample data with n_c clusters = 3





Cluster 0: 15347 clients

Cluster 1: 74688 clients

Cluster 2: 2710 clients

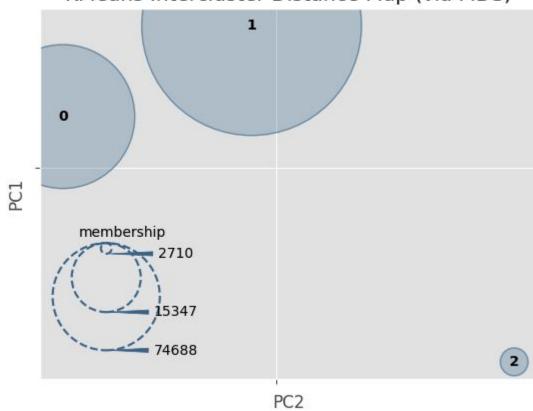
- Silhouette Score: 0.40

- calinski_harabasz Score: 25600

- davies_bouldin Score: 1.18

KMeans Intercluster Distance Map (via MDS)

La distance intercluster permet de voir une dissimilarité entre les clusters

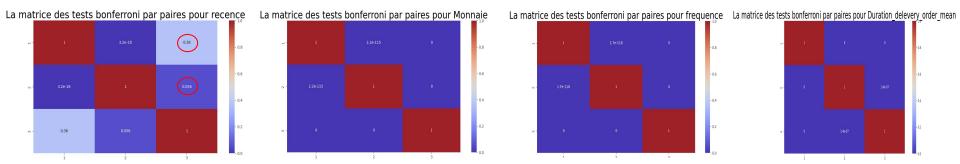


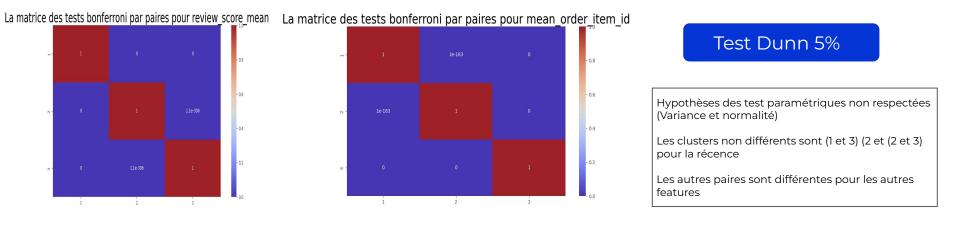
Déterminer si un cluster est différents des autres

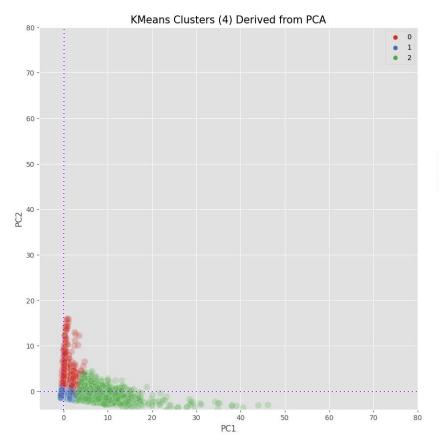
Kruskal-wallis Test 5%

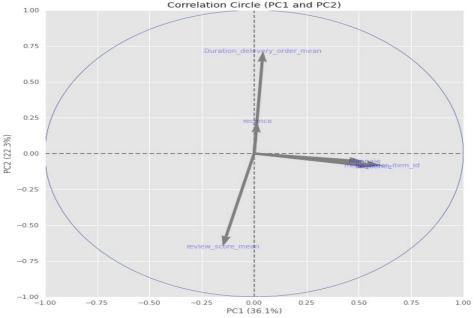
- stat=60105.071, p=0.000 recence moyenne
- stat=19657.082, p=0.000 fréquence
- stat=6645.377, p=0.000 Monnaie
- stat=41808.725, p=0.000review score mean
- stat=12074.576, p=0.000Duration_delevery_order_mean
- > stat=25552.940, p=0.000 mean_order_item_id

Déterminer si les clusters par paires sont différents





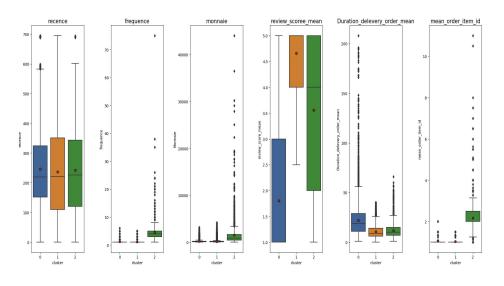




PC1:Monnaie, mean_order_item_d, fréquence

PC2: review_score_mean, Duration_delevery_order_mean

Analyse des clusters



Client

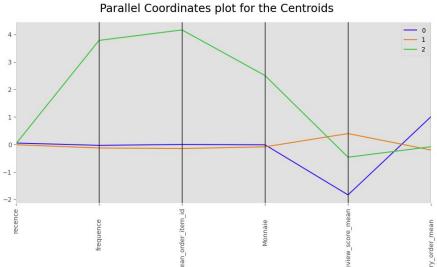
insatisfait

dépensier

16.55 %

très

peu



cluster 0

- fréquence:1

- Moyenne articles: 1

Dépense moyenne : 203

Satisfaction moyenne:

1.80

Durée livraison moyenne :22 jours

cluster 1

fréquence : 1

Moyenne articles : 1 Dépense moyenne : 165.26

Satisfaction moyenne : 4.65

Durée livraison moyenne : 10 jours

Client très satisfait peu dépensier 80.53 %

Cluster 2

fréquence : 4

Moyenne articles : 2Dépense moyenne : 1509.46

Satisfaction moyenne : 3.55

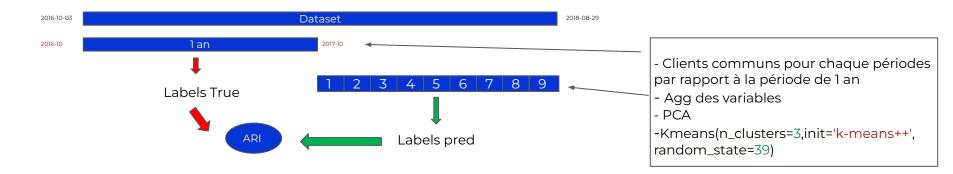
- Durée livraison moyenne : 11 jours

Best client satisfaction moyenne très dépensier

2.92 %

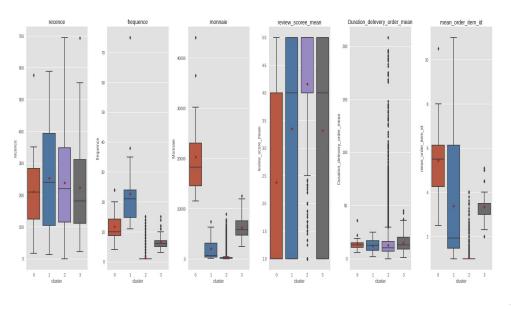
n

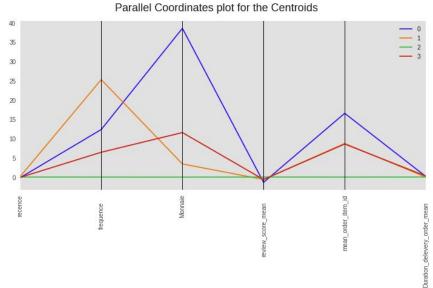
Stabilité temporelle





Algorithme BIRCH





Effectifs

cluster 0:24 cluster 1:24

cluster 2 : 92589

cluster 3:108

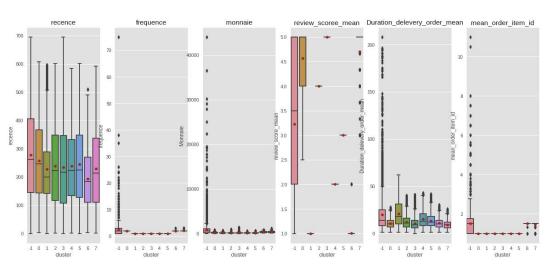
Evaluation

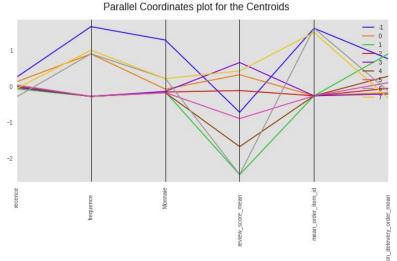
- Silhouette Score: 0.84
- calinski_harabasz Score: 6164.79
- davies_bouldin Score: 0.68

Conclusion

Le clustering ne permet pas de répondre à la problématique métier (Les effectifs des clusters sont trop hétérogène pour effectuer des stratégies marketing)

Algorithme HDBSCAN





Effectifs

Evaluation

- Silhouette Score: 0.09
- calinski_harabasz Score: 5985.50
- davies_bouldin Score: 2.62

Conclusion

- Le clustering ne permet pas de répondre à la problématique métier (Les effectifs des clusters sont trop hétérogène pour effectuer des stratégies marketing)
- Les métriques indiquent que la segmentation n'est pas pertinente

Conclusion

La segmentation finale porte sur 6 variables :

- ➤ Recence
- Fréquence
- ➤ Monnaie
- > Review_score_mean
- Mean_order_item_id
- Duration_delevery_order_mean

Le modèle final choisis est le Kmeans:

- 3 clusters
- Stable à l'initialisation avec 10 itérations.
- > Le clustering permet d'identifier des profils clients afin d'adapter une stratégie marketing pour chaque clusters
- > Le clustering permet de segmenter les bons et moins bons clients en termes de commandes et de satisfaction.

contrat de maintenance

- > Stabilité fortement dépendante des variables choisies
- ➤ La fréquence à laquelle la segmentation doit être mise à jour est 5 mois pour qu'elle reste pertinente